TECH CHALLENGE · FASE 2

Olist Intelligent Marketplace

Relatório Executivo e Visão Estratégica de IA Agêntica

Versão 2.1 · evolução do relatório da Fase 1 com os entregáveis da Fase 2

Pós-graduação em IA Agêntica · FIAP

Base: Brazilian E-Commerce Public Dataset by Olist (2016–2018) · 99.441 pedidos · R$ 16 milhões

Versão final · 27 de outubro de 2026

Equipe

Leonardo Granjeiro · lgranjeiro@bol.com.br
Jorge Leandro Piva · jorgelpiva@gmail.com
Caio Sousa · caio.rios.sousa@gmail.com
Lucas Vinicius Oliveira Mendes · lucasviniciusom@gmail.com

Pergunta central (Fase 1)

"Como a Olist poderia utilizar IA Generativa e Agentes de IA para melhorar sua operação e seus indicadores de negócio?"

Pergunta da Fase 2

"Como os agentes de IA irão interagir com usuários, dados e processos da Olist para gerar valor real ao negócio?"

Vídeo executivo (Fase 2): https://drive.google.com/file/d/1PJSLsUUfmOJyO6yJfI5DWCG1B4v5P29G/view?usp=sharing
Repositório: https://github.com/jorgelpiva/tech-challenge-fiap-agentes-ia

Histórico do Documento

Versão	Data	Fase	Conteúdo
1.0	26/08/2026	Fase 1 · Identificar oportunidades	Diagnóstico do dataset, mapa de 6 agentes, arquitetura conceitual, prompts iniciais, riscos e roadmap
2.0	**14/10/2026**	**Fase 2 · Estruturar casos de uso e desenho dos agentes**	Fase 1 revisada + priorização, casos de uso detalhados, jornadas, prompts v2 e business case
2.1	**27/10/2026**	**Fase 2 · Revisão final de consistência**	Alinhamento com a apresentação executiva; qualificação de saídas ilustrativas; separação entre histórico e simulação; governança das filas humanas; baseline do WinBack medido na janela de atuação do agente; meta do Nordeste recalculada

O que mudou da versão 1.0 para a 2.0

Aprendizado da avaliação da Fase 1	Como a versão 2.0 responde	Onde
Detalhar o racional de onde partiram os achados	Cada achado ganhou uma **cadeia de evidência**: pergunta → tabela/coluna → método → resultado → decisão de desenho	Seção 4.5
Ações dos agentes muito amplas	Cada agente priorizado tem **um objetivo**, **gatilhos definidos**, **lista fechada de ações** e um quadro do que **não faz**	Seções 8 a 10
Muitos objetivos; priorizar o mais próximo do negócio	**Matriz de priorização** ponderada: dos 6 agentes, **3 detalhados**, todos na jornada do pedido	Seção 5.3
Falha de revisão	Fonte única de números gerada por notebook, revisão de consistência e apêndice de rastreabilidade	Apêndice A

Ajustes da versão 2.1 em relação à 2.0: alinhamento com a apresentação executiva; exemplos de prompts qualificados como ilustrativos; caso multiagente separado em evidências e intervenções hipotéticas; comunicação condicionada a políticas operacionais; integração pós-entrega tratada como sinal histórico; feedback loop e SLA de 4 horas úteis para as filas humanas (11.5); **baseline do WinBack recalculado na janela em que o agente atua** (0,90%, antes 1,13%; business case inalterado); **baseline do piloto no Nordeste corrigido** para 14,3% (antes "15–24%").

Correções em relação à versão 1.0: tempo médio de entrega padronizado em **12,56 dias**, com trânsito de 9,33 dias e processamento de 3,23 dias (recalculados no notebook 08). O "tempo de resposta a reviews de 3,15 dias" foi reinterpretado: a coluna `review_answer_timestamp` registra quando o **cliente respondeu a pesquisa**, não quando a Olist respondeu. O roadmap, que tinha duas ordens diferentes na versão 1.0, foi unificado.

1. Sumário Executivo (atualizado na Fase 2)

Solicitamos aprovação para desenhar e validar, em um piloto controlado de 90 dias, dois agentes — LogiPredict e SentimentDesk — em rotas selecionadas do Nordeste. A autorização solicitada é para uma etapa de validação operacional, não para implantação corporativa ou reconhecimento antecipado dos benefícios estimados. Esse pedido é a evolução direta do diagnóstico da Fase 1, que mapeou onde a Olist perde valor: recompra de apenas **3,00%**, **8,11%** dos pedidos entregues com atraso, frete em **21,34%** do valor do pedido e **14,7%** das avaliações em nota 1 ou 2. Na Fase 2, a diretoria aprovou a continuidade e perguntou: **como os agentes vão interagir com usuários, dados e processos para gerar valor real?**

A resposta parte de uma constatação: esses problemas nascem no mesmo lugar, **a jornada do pedido**. Quando o pedido atrasa, **54%** dos clientes dão nota 1 ou 2 (contra 9% no prazo); **27%** dos atrasos começam antes da transportadora, com o seller postando depois do limite; e quem teve a 1ª compra atrasada volta menos (1,56% contra 2,13%). Por isso, **dos seis agentes da Fase 1, priorizamos três que atuam em sequência nessa jornada** — LogiPredict (Guardião do Prazo), SentimentDesk (Triagem de Avaliações Negativas) e WinBack (Segunda Compra) —, cada um com um objetivo único, gatilhos definidos e uma lista fechada de ações. O SellerCare foi absorvido pelos dois primeiros, o SmartFreight segue no backlog e o Maestro orquestra a partir da Fase 4 (priorização completa na Seção 5.3).

Potencial estimado, não resultado observado: em um horizonte anual e na escala da amostra histórica do dataset, o cenário base dos **dois agentes do piloto** corresponde a 672 atrasos evitados, 302 avaliações negativas a menos e 1.230 horas de triagem poupadas (equivalentes a aproximadamente R$ 55 mil de capacidade operacional). **Separadamente, na expansão futura**, o WinBack tem potencial estimado de 358 segundas compras adicionais (aproximadamente R$ 53 mil de receita bruta incremental). Nenhum desses valores representa meta de entrega integral nos 90 dias, economia de caixa comprovada ou retorno líquido. Premissas e contas: Seção 13.4.

A aprovação do piloto fica condicionada à definição do volume elegível, desenho dos grupos comparáveis, acesso aos dados e canais, responsáveis pelas intervenções e orçamento de execução. A visão de seis agentes orquestrados pelo Maestro, proposta na Fase 1, continua sendo o destino. A Fase 2 dá a ela um primeiro passo concreto, com ordem e critério: **não propomos mais agentes, propomos agentes melhores**, começando pela origem do problema — e cada onda seguinte só avança com resultado medido na anterior (roadmap completo na Seção 12).

Links: vídeo executivo da Fase 2: https://drive.google.com/file/d/1PJSLsUUfmOJyO6yJfI5DWCG1B4v5P29G/view?usp=sharing · vídeo da Fase 1: https://drive.google.com/file/d/1t1Yk40IJMqkFO4Q3YDFspaHaz7X0K7UJ/view?usp=sharing · repositório: https://github.com/jorgelpiva/tech-challenge-fiap-agentes-ia

As metas apresentadas são hipóteses de impacto para validação em piloto, não resultados comprovados pelo dataset histórico.

2. Contexto e Problema de Negócio

O case propõe que a Olist inicie sua jornada de transformação com IA Generativa e Agentes de IA, buscando melhorar experiência do cliente, eficiência logística, retenção, análise de reviews, eficiência operacional, automação e apoio à decisão.

2.1 Diagnóstico em quatro fricções prioritárias

Fricção	Evidência
Retenção e fidelização	93.358 clientes únicos e apenas 3,00% de recompra; LTV estimado de R$ 165,20, próximo ao ticket médio de R$ 161,00
Logística e custo de servir	Tempo médio de entrega de 12,56 dias; 8,11% de atrasos; 63,8% das vendas interestaduais; frete equivalente a 21,34% do pedido
Experiência e reviews	57,8% das avaliações são nota 5, porém 11,5% são nota 1 e 3,2% nota 2; comentários negativos concentrados em entrega
Qualidade e concentração de sellers	3.095 vendedores; Gini 0,792; 17,6% geram 80% da receita; 342 com nota média abaixo de 3,0 e 527 no cluster problemático

2.2 A pergunta da Fase 2 (novo na Fase 2)

A Fase 1 respondeu **onde** a IA pode gerar valor. A Fase 2 responde **como**: *"Como os agentes de IA irão interagir com usuários, dados e processos da Olist para gerar valor real ao negócio?"* Isso exige descer do mapa de oportunidades para o desenho operacional: gatilhos, decisões, pessoas envolvidas, dados de entrada e resultados mensuráveis.

3. Abordagem Analítica (atualizado na Fase 2)

Foram analisadas oito frentes complementares do dataset. O detalhamento técnico permanece nos notebooks do projeto.

Frente	Finalidade executiva
EDA e qualidade de dados	Compreender pedidos, receita, preço, frete, prazos e dados ausentes
RFM + K-Means de clientes	Identificar grupos de comportamento e oportunidades de retenção
K-Means de vendedores	Separar perfis de performance e apoiar ações de seller success
Correlações	Explorar relações entre distância, frete e prazo
Testes de hipótese	Avaliar associação estatística entre atraso e avaliação do cliente
Análise geoespacial	Estimar distâncias origem-destino e identificar rotas críticas
NLP básico em reviews	Extrair termos e temas recorrentes de avaliações negativas
Evidências para desenho dos agentes *(novo, notebook 08)*	Origem do atraso, taxonomia de motivos das avaliações 1–2, janela da 2ª compra, priorização e business case

3.1 Nota de interpretação estatística

Os testes Mann-Whitney U, Chi-Quadrado e as correlações sustentam **associação** entre variáveis, não causalidade. Por isso, cada agente é proposto com **grupo controle no piloto**, para medir o efeito real.

3.2 Evidência, premissa e validação (novo na revisão executiva)

Para evitar confusão entre diagnóstico e resultado futuro, este relatório adota três classificações: **(i) observado** = calculado no dataset histórico; **(ii) premissa** = parâmetro definido pelo grupo, ainda não comprovado; **(iii) projeção** = resultado aritmético que combina observações e premissas. Exemplos: 8,11% de atraso é observado; eliminar 50% da diferença entre grupos é premissa; 672 atrasos evitados é projeção. **Não se infere causalidade nem desempenho de produção a partir da associação histórica.** O piloto deverá medir impacto incremental frente a controle comparável.

3.3 Limitações do diagnóstico

- O dataset é histórico (2016–2018) e não representa necessariamente a operação atual da Olist.
- Churn e LTV dependem das definições adotadas no projeto.
- O dataset não contém o tempo de resposta da Olist às avaliações: esse baseline será **medido no piloto**.
- Metas de impacto são hipóteses a testar em pilotos controlados.

4. Principais Achados (atualizado na Fase 2)

4.1 Retenção: a maior oportunidade econômica

A recompra de 3,00% indica que 97 em cada 100 clientes não fazem uma segunda compra. A segmentação RFM identifica 40% da base no grupo "Em Risco", e o Top 10% dos clientes concentra 38,25% da receita. **Novo na Fase 2:** quando o cliente volta, volta cedo. A mediana até a 2ª compra é de 76 dias, e **54%** das segundas compras ocorrem em até 90 dias (37% entre D+7 e D+90 após a entrega, a janela do WinBack).

4.2 Logística: o principal ponto de atrito operacional

O tempo médio total de entrega é de **12,56 dias**. O trânsito responde por **9,33 dias (74%)** e o processamento do seller por 3,23 dias. A taxa de atraso é de 8,11%, mais alta em AL (23,9%), MA (19,7%) e PI (16,0%). **Novo na Fase 2:** quando o seller posta depois do limite (9,0% dos pedidos), o atraso sobe para **24,4%**, contra 6,5% quando posta no prazo.

4.3 Reviews: atraso e satisfação caminham em direções opostas

A nota 5 representa 57,8% das avaliações, mas há uma cauda de detratores: 11,5% nota 1 e 3,2% nota 2. A correlação entre tempo de espera e nota é negativa (-0,229; $p < 0,001$). **Novo na Fase 2:** com atraso, **54,1%** das avaliações são 1–2, contra 9,2% no prazo; e **47%** dos comentários negativos falam de entrega.

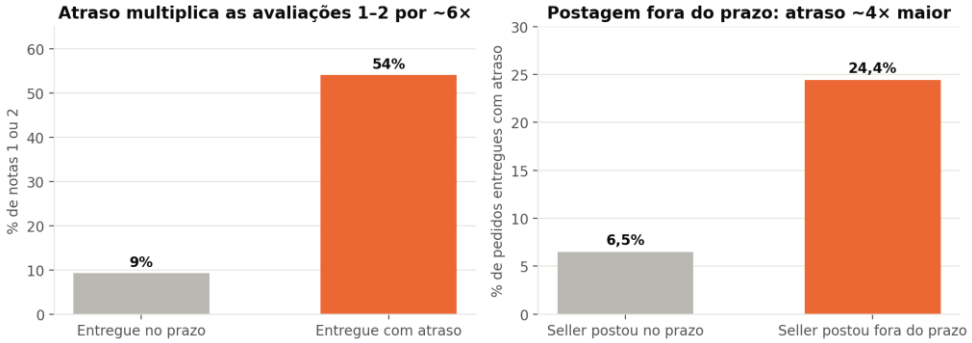
4.4 Sellers: concentração e heterogeneidade de performance

Dos 3.095 vendedores, 17,6% respondem por 80% da receita. Há 342 sellers com nota média inferior a 3,0 e 527 no cluster "Problemáticos" (nota 2,22, entrega de 14,4 dias). São critérios diferentes e não devem ser tratados como equivalentes.

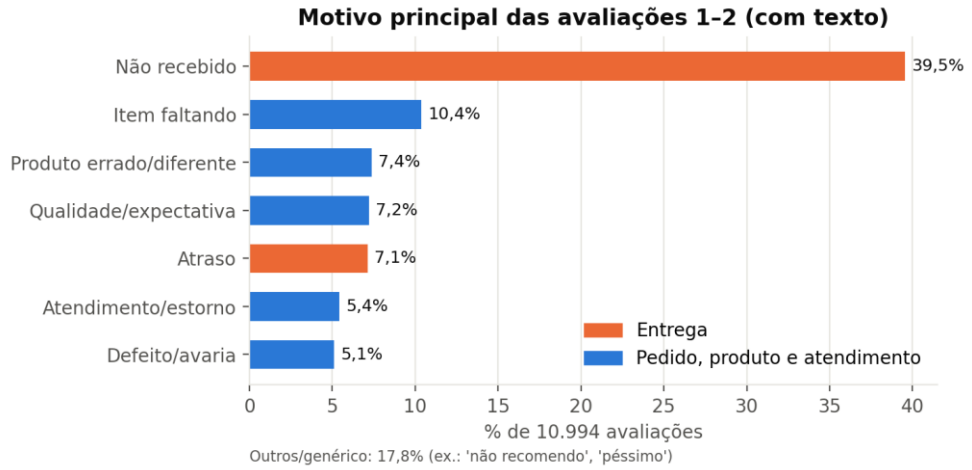
4.5 Da evidência à decisão (novo na Fase 2)

Para responder à pergunta *"de onde partiram os achados?"*, cada evidência que orienta o desenho dos agentes é apresentada com sua origem nos dados.

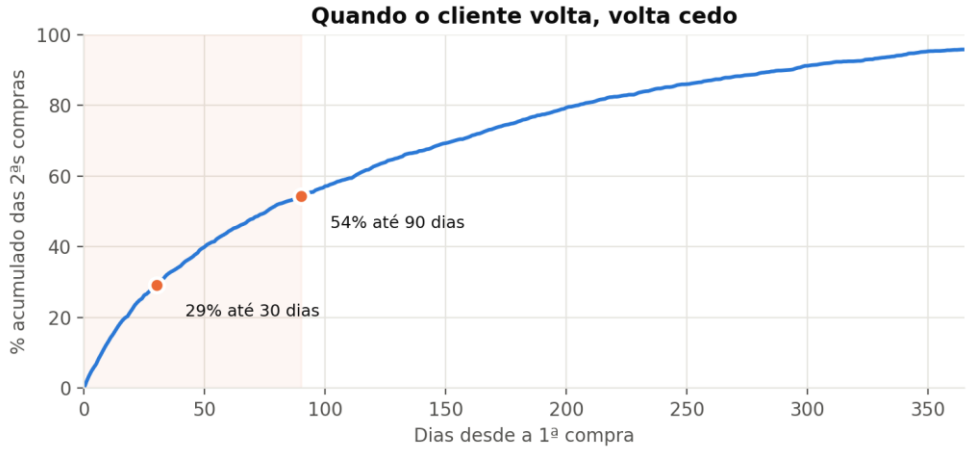
#	Pergunta de negócio	Dado utilizado	Método	Resultado	Decisão de desenho
E1	O atraso pesa na satisfação?	`orders` (entrega × prazo) + `order_reviews`	Proporções por pontualidade	**54,1%** de notas 1–2 com atraso vs **9,2%** no prazo	Atraso é o primeiro problema a atacar
E2	Onde o atraso nasce?	`order_items.shipping_limit_date` × `orders.order_delivered_carrier_date`	Atraso segmentado pela postagem	Atraso de **24,4%** vs **6,5%**; **27%** dos atrasos	1º checkpoint do LogiPredict: limite de postagem
E3	Onde o atraso é mais provável?	`orders` + `customers` (UF destino)	Taxa de atraso por UF	AL 23,9%, MA 19,7%, PI 16,0% (média 8,11%)	UF no score de risco; piloto no Nordeste
E4	Do que reclamam os insatisfeitos?	`order_reviews` (título + comentário)	Classificação por regras em 10.994 avaliações	**47%** entrega, **18%** pedido incorreto, **12%** produto, **5%** atendimento	Taxonomia fixa do SentimentDesk
E5	Quando o cliente volta?	`orders` + `customer_unique_id`	Intervalo entre 1ª e 2ª compra	Mediana de **76 dias**; **54%** em até 90 dias	WinBack atua de D+7 a D+90
E6	A experiência afeta a recompra?	`orders` + `order_reviews`	Recompra por pontualidade da 1ª compra	1,56% (atrasou) vs 2,13% (no prazo)	WinBack pausa a oferta após experiência ruim



Atraso e satisfação (E1) e origem do atraso na postagem do seller (E2).



Motivo principal das avaliações 1–2 com comentário (E4). Laranja: motivos ligados à entrega.



Distribuição acumulada do tempo até a 2ª compra (E5).

5. Segmentação e Priorização (atualizado na Fase 2)

5.1 Clientes: RFM K=4

Segmento	Qtd.	Recência média	Valor médio	Leitura executiva
Novos	54%	178 dias	R$ 135	Maior grupo; primeira compra recente. **Público natural do WinBack na Fase 2**
Em Risco	40%	439 dias	R$ 135	Base inativa; baixa probabilidade de retorno (E5)
Campeões Alto Valor	3%	290 dias	R$ 1.196	Ticket muito superior; retenção prioritária
Campeões Recorrentes	3%	269 dias	R$ 290	Maior frequência relativa

5.2 Vendedores: K=3

Segmento	Qtd.	Receita média	Nota	Leitura executiva
Regulares	82%	R$ 3.775	4,33	Base sólida; foco em escala e eficiência
Top Performers	1%	R$ 102.986	4,03	Alta relevância econômica e pressão operacional
Problemáticos	17% (527)	R$ 1.299	2,22	Baixa satisfação e entrega média de 14,4 dias

5.2.1 Por que iniciar no Nordeste? (novo na revisão executiva)

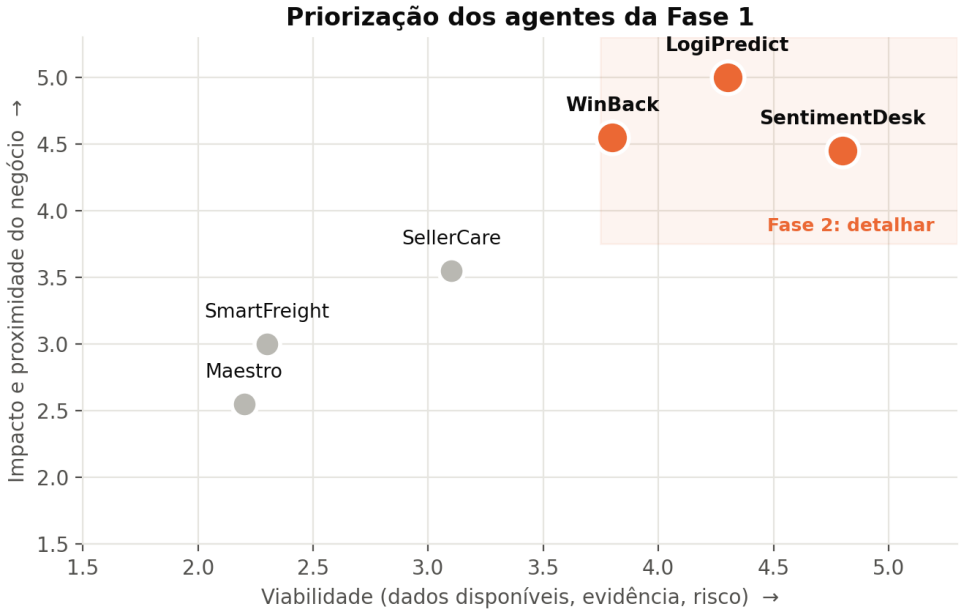
No agregado, os pedidos com destino aos 9 estados do Nordeste (9.044 entregas) tiveram **14,3%** de atraso, contra 8,11% na média do dataset, variando de 10,8% a 23,9% por UF; AL (23,9%), MA (19,7%) e PI (16,0%) são os mais altos, justificando a **hipótese de priorização** das rotas da região. **Isso não basta para comprovar que o Nordeste maximiza retorno ou é operacionalmente viável.** Antes do piloto, a equipe deverá apurar: (1) volume de pedidos elegíveis por rota e seller; (2) concentração de atrasos evitáveis, especialmente na postagem; (3) disponibilidade e qualidade de rastreio e canais de contato; (4) capacidade de intervenção de Operações/CX; (5) custos por pedido e risco de contaminação entre grupos. As rotas definitivas devem ser selecionadas com esses critérios, não somente pelo percentual de atraso.

Desenho de medição proposto: estabelecer baseline recente; alocar unidades comparáveis entre tratamento e controle (preferencialmente aleatorização por seller/rota, conforme risco de contaminação); definir previamente janela, métricas, exclusões e tamanho de amostra; comparar diferenças ajustadas por mix de rota, seller e sazonalidade. A forma final de alocação e o tamanho de amostra **ainda dependem dos volumes reais**, não disponíveis no material fornecido.

5.3 Priorização dos agentes (novo na Fase 2)

Na Fase 1, o critério de priorização foi descrito de forma qualitativa. Na Fase 2, os seis agentes foram pontuados em cinco critérios ponderados. **Proximidade do core** mede se o agente atua diretamente na jornada compra → entrega → avaliação → recompra.

Agente	Impacto (30%)	Proximidade do core (25%)	Evidência (20%)	Viabilidade (15%)	Risco, inverso (10%)	Score	Decisão
LogiPredict	5	5	5	4	4	**4,75**	Detalhar
SentimentDesk	4	5	5	5	4	**4,60**	Detalhar
WinBack	5	4	4	4	3	**4,20**	Detalhar
SellerCare	4	3	4	3	2	3,40	Absorvido / Wave 3
SmartFreight	3	3	3	2	2	2,75	Backlog
Maestro	3	2	2	2	3	2,40	Fase 4



Matriz impacto × viabilidade dos seis agentes.

6. Mapa de Agentes de IA (atualizado na Fase 2)

O ecossistema da Fase 1 é mantido como visão de longo prazo. A coluna "Fase 2" mostra o que foi decidido para cada agente.

Agente	Objetivo	Problema	Usuários	Fase 2
LogiPredict	Proteger o prazo prometido, agindo antes do vencimento	8,11% de atrasos; 27% começam na postagem	Operações, sellers, clientes	**Detalhado** (Seções 8 a 10)
SentimentDesk	Classificar, responder e rotear avaliações 1–3	14,7% notas 1–2; motivos não estruturados	CX, sellers, clientes	**Detalhado**
WinBack	Converter a 1ª compra em 2ª na janela de 90 dias *(antes: reativar a base inativa)*	Recompra de 3%; 0,90% voltam entre D+7 e D+90 após a entrega	CRM, Marketing, clientes	**Detalhado** e reposicionado
SellerCare	Diagnosticar sellers e gerar coaching	527 sellers problemáticos	Comercial, KAMs	Lembrete de postagem → LogiPredict; ticket ao seller → SentimentDesk; coaching na Wave 3
SmartFreight	Otimizar frete e precificação	Frete = 21% do pedido	Financeiro, Comercial	Backlog
Maestro	Orquestrar especialistas e apoiar decisões	Dados fragmentados	C-Level, diretores	Fase 4 (orquestração)

6.1 Interações entre os agentes priorizados

Na Fase 1, foram mapeadas 6 interações entre os 6 agentes. Na Fase 2, as interações essenciais foram reduzidas a **três sinais simples** entre os agentes priorizados:

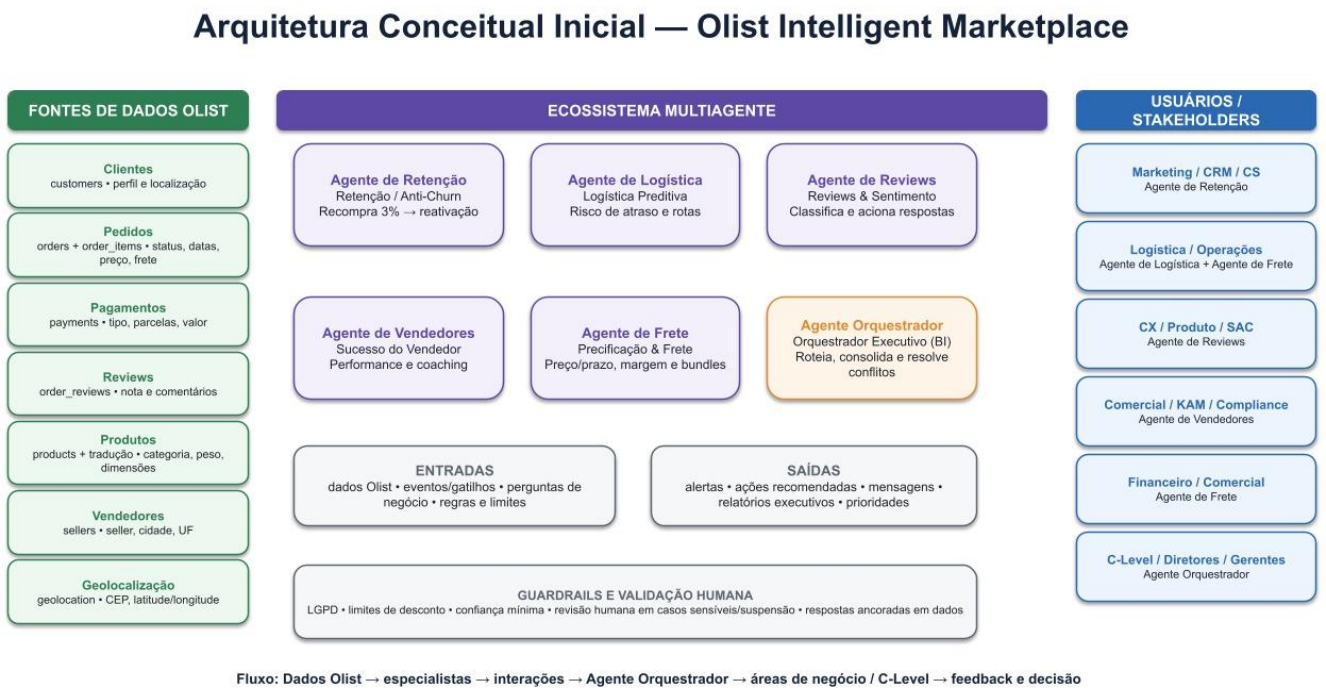
- **LogiPredict → SentimentDesk:** "pedido em risco", para que a resposta a uma avaliação já considere o atraso.
- **SentimentDesk → LogiPredict:** "motivo = entrega" como **sinal histórico** para análise de padrões de falha por rota e seller e eventual recalibração futura, **não** como intervenção retroativa em pedido já entregue.
- **SentimentDesk → WinBack:** "pausar", que impede oferta comercial a um cliente com problema aberto.

6.2 Decisões de escopo

- Na Fase 1, o grupo indicou um agente de atendimento (SAC) como candidato para a Fase 2. A decisão foi **não criar um 7º agente**: o contato com o cliente é coberto pelo SentimentDesk (avaliações) e pelo LogiPredict (aviso proativo).
- Cross-sell continua sem agente próprio. A recomendação de categoria foi incorporada ao WinBack, baseada nas 2ªs compras reais (38% na mesma categoria da 1ª).

7. Arquitetura Conceitual (atualizado na Fase 2)

A arquitetura da Fase 1 continua válida: fontes de dados → processamento analítico → agentes especialistas ↔ orquestrador → usuários, com guardrails e validação humana.



Arquitetura conceitual da Fase 1, mantida como visão de longo prazo.

7.1 Princípio de autonomia responsável

Autonomia não significa ausência de controle. Ações reversíveis e de baixo impacto podem ser automatizadas; decisões financeiras, comerciais ou reputacionais exigem aprovação humana e trilha de auditoria.

7.2 Visão operacional dos agentes priorizados (novo na Fase 2)

	LogiPredict	SentimentDesk	WinBack
Momento da jornada	Aprovação → entrega	Após a avaliação	D+7 a D+90 após a 1ª entrega
Frequência	Varredura a cada 6h + eventos	Por avaliação (tempo real)	Batch diário
Usuários que recebem	Analista de Operações, seller, cliente	Analista de CX, seller, cliente	Analista/Gestor de CRM, cliente
Sistemas tocados	Pedidos, rastreio, mensageria	Avaliações, tickets, mensageria	CRM, catálogo, mensageria
Nunca faz sozinho	Trocar transportadora, compensar cliente	Reembolso, cupom, penalizar seller	Incentivo > 10%, contato sem opt-in

8. Casos de Uso Detalhados (novo na Fase 2)

Na Fase 1, esta seção trazia um parágrafo de caso de uso e guardrails por agente. Na Fase 2, os três agentes priorizados são detalhados nos seis elementos pedidos: **a) objetivo, b) problema, c) usuários, d) dados, e) entradas e saídas, f) indicadores**, além de um quadro do que o agente faz e não faz e da comparação entre o processo atual e o processo com o agente.

8.1 LogiPredict · Guardião do Prazo de Entrega

a) Objetivo. Reduzir pedidos entregues após o prazo prometido, agindo **antes do vencimento** em três checkpoints: limite de postagem, postagem efetiva e D-3 do prazo.

b) Problema resolvido. 8,11% dos pedidos atrasam, e em pedidos atrasados **54%** das avaliações são nota 1–2. O trânsito responde por **74%** do tempo de entrega, mas **27%** dos atrasos começam com o seller postando depois do limite. Hoje o atraso só aparece quando o cliente reclama. A consequência é perda de reputação, avaliação negativa e menor recompra.

c) Usuários envolvidos. Analista de Operações Logísticas (decide a tratativa), seller (recebe lembrete), cliente (recebe aviso com nova data), Gestor de Logística (painel por rota).

d) Dados utilizados.

Tabela / fonte	Informação relevante
`orders`	Compra, aprovação, postagem, entrega, prazo estimado
`order_items`	`shipping_limit_date` (limite de postagem), seller
`sellers`, `customers`, `geolocation`	UF de origem e destino, distância
Calculado (notebook 08)	Trânsito mediano/p75/p90 por rota; atraso por UF; histórico de postagem do seller
Externo	Eventos de rastreio da transportadora, feriados, greves, clima

e) Entradas e saídas.

Entrada	Saída
Pedido a 24h do limite sem postagem	Lembrete ao seller + ocorrência registrada
Postagem efetiva	Score de risco (0–100) com fatores + ação (monitorar ou escalar)
D-3 do prazo sem entrega	Se projeção validada ultrapassar o prazo, comunicação ao cliente condicionada a política e template aprovados
Fechamento diário	Painel de risco por rota/UF; sinal "pedido em risco" ao SentimentDesk

f) Indicadores impactados. Taxa de atraso (8,11%), postagens após o limite (9,0%), notas 1–2 em pedidos de risco, contatos "onde está meu pedido", falso positivo dos alertas. **Distinguir:** qualidade preditiva (precisão/recall, falsos alertas, calibração por rota) e efeito da intervenção (redução incremental de atrasos frente ao controle). Um alerta correto não significa, necessariamente, atraso evitado.

Faz	Não faz
Calcula risco, lembra o seller, alerta operações, avisa o cliente com data projetada	Não troca transportadora, não negocia frete, não concede compensação, não avisa o cliente sem projeção de estouro

Hoje *(processo presumido, a validar com a área)*	Com o LogiPredict
O atraso é descoberto quando o cliente reclama	Risco identificado na postagem; nos pedidos que atrasaram, a postagem ocorreu em mediana **17,5 dias antes do prazo**
O seller não é lembrado do limite de postagem	Lembrete automático 24h antes do limite
Aviso ao cliente inexistente ou genérico	Aviso com nova data, só quando a projeção estoura o prazo

8.2 SentimentDesk · Triagem e Resposta de Avaliações Negativas

a) Objetivo: interpretar e encaminhar. Classificar avaliações nota 1 a 3, priorizar o atendimento e preparar resposta e encaminhamento. O motivo descreve o relato; a causa e o responsável pela falha dependem de apuração.

b) Problema: reclamações sem triagem. 14,7% das avaliações são nota 1 ou 2, cerca de **11,7 mil por ano**. **47%** dos comentários de notas 1–2 foram classificados por regras como entrega e **18%** de pedido incorreto. Sem triagem, o caso grave fica na mesma fila do simples e o seller reincidente não é identificado. A consequência é detrator não recuperado e problema recorrente sem dono.

c) Usuários: cliente, CX e sellers. Cliente (recebe resposta), Analista de CX (revisa casos críticos e define compensação), seller (recebe ticket), Gestor de CX (dashboard de motivos).

d) Dados: contexto disponível na avaliação.

Tabela / fonte	Informação relevante
`order_reviews`	Nota, título, comentário, data
`orders`	Datas e status conhecidos no instante da avaliação; não usar entrega futura
`order_items`, `products`, `sellers`	Nº de itens/sellers, categoria e vínculo item → seller, quando disponível
`order_payments`	Valor do pedido (critério de alçada)
Externo	Tickets, contatos, resolução confirmada, SLA aprovado e confirmação de execução; ausências são desconhecidas

e) Entradas e saídas: decisão antes da execução.

Entrada	Saída
Avaliação nota 1–3 (com ou sem texto) + dados do pedido	Motivo (taxonomia de 8), severidade, responsável e resumo
	Resposta ao cliente (até 600 caracteres) ou rascunho para revisão
	Encaminhamento proposto à fila responsável; seller a confirmar se faltar vínculo com o item; pausa do WinBack para qualquer problema aberto
	Dashboard semanal de motivos por seller e categoria

f) Indicadores: qualidade e tempo de atendimento. Tempo até a 1ª resposta (a medir), detratores com caso resolvido, classificação correta em auditoria, reincidência por seller e nota média. Medir também recall dos casos críticos, escalonamento indevido e respostas inadequadas: acurácia agregada pode esconder falhas graves.

Faz	Não faz
Classifica e prepara rascunho; processo abre/atualiza ticket, confirma execução e só então envia resposta autorizada	Não promete reembolso, troca ou cupom; não penaliza seller; não responde caso crítico sem revisão humana

Hoje *(presumido)*	Com o SentimentDesk
Avaliação negativa lida manualmente, sem padrão de motivo	Motivo, severidade e responsável em segundos
Casos graves e simples na mesma fila	Casos críticos vão direto ao analista, com resumo
Seller reincidente invisível	Dashboard de motivos por seller

Regras de revisão: incerteza, severidade e envio

Sem comentário, o motivo é OUTROS e o atraso é apenas uma hipótese, com revisão humana. Conflito de dados é CRÍTICO. Valor acima de R$ 500, valor ausente, contexto essencial ausente, responsável a confirmar ou confiança abaixo de 0,8 exigem revisão. A confiança é estimativa do modelo, ainda não calibrada. O roteamento define a fila que apura, não a culpa pela falha.

Integração: problema aberto e resolução confirmada

Qualquer reclamação aberta, inclusive de produto, pausa ofertas do WinBack. Somente o atendimento confirma a resolução; esse evento libera uma nova avaliação de elegibilidade, sem oferta ou cupom automático. Motivo de entrega confirmado gera sinal ao LogiPredict.

Limites: ações e prazos confirmados

O prompt isolado não abre tickets nem envia mensagens. Expressões como “já acionamos” dependem de retorno confirmado da ferramenta. Um SLA de dois dias úteis é hipótese de política de CX a aprovar, não dado do dataset; sem SLA fornecido, não informar prazo. O prazo, quando aprovado, é de retorno, não de solução. O processo deve registrar confirmação e impedir tickets/envios duplicados.

8.3 WinBack · Segunda Compra

a) Objetivo: favorecer a segunda compra. Aumentar a conversão da **1ª para a 2ª compra** com contato relevante e no momento certo, dentro da janela de 90 dias.

b) Problema: baixa recorrência observada. Só **3,0%** dos 93.358 clientes compram de novo, e só **0,90%** fazem a 2ª compra na janela em que o agente atua (D+7 a D+90 após a entrega). Quando o cliente volta, volta cedo: **54%** das segundas compras acontecem em até 90 dias após a 1ª compra, e **37%** caem exatamente na janela do agente. A ausência de ação estruturada nessa janela é hipótese do case, não informação comprovada pelo dataset. A consequência é custo de aquisição pago para uma única venda. **Mudança em relação à Fase 1:** o alvo deixou de ser a base inativa há mais de 439 dias, que tem baixa probabilidade de retorno.

c) Usuários: cliente e equipe de CRM. Cliente (recebe mensagem), Analista de CRM (acompanha campanhas), Gestor de CRM (aprova incentivo acima do teto), Marketing (relatório de uplift).

d) Dados: elegibilidade e contexto comercial.

Tabela / fonte	Informação relevante
`orders`, `customers`	1ª compra, data de entrega, recorrência (`customer_unique_id`)
`order_items`, `products`	Categoria da 1ª compra; categorias da 2ª compra por perfil
`order_reviews`, `order_payments`	Nota e valor da 1ª compra; estado do problema e resolução vêm do atendimento
Externo	Opt-in/opt-out, último contato e contador, grupo persistente, catálogo elegível, orçamento e aprovação de incentivo

e) Entradas e saídas: pausa e reavaliação.

Entrada	Saída
Cliente atinge D+7 após a 1ª entrega	Decisão: não contatar, pausar ou enviar mensagem (com ou sem incentivo)
Sinal "pausar" do SentimentDesk	PAUSAR: nenhuma oferta enquanto houver problema aberto
Resolução confirmada pelo atendimento	Reavaliar todos os bloqueios; sem oferta ou cupom automático
Fim do ciclo de 90 dias	Relatório de uplift contra o grupo controle (10%)

f) Indicadores: conversão e efeito incremental. Conversão em 2ª compra de D+7 a D+90 após a entrega (0,90%), recompra (3,0%), receita por cliente, uplift contra o controle, opt-out e margem incremental após incentivos e custos de contato.

Faz	Não faz
Processo verifica elegibilidade e separa controle antes da oferta; IA propõe categoria e rascunho	Não contata sem opt-in, não passa de 2 contatos, não dá incentivo > 10% sem aprovação, não atua na base inativa antiga

Hoje *(presumido)*	Com o WinBack

Hoje *(presumido)*	Com o WinBack
Campanhas de massa, sem considerar a experiência da 1ª compra	Contato individual, no tempo certo, que pausa quando a experiência foi ruim
Sem medição de efeito incremental	Grupo controle permanente e uplift medido

Regras de contato: verificações antes de cada envio

O processo verifica segunda compra, janela D+7–D+90, consentimento, opt-out, intervalo mínimo de 15 dias e máximo de dois contatos confirmados. Primeiro contato de D+7 em diante; segundo somente de D+45 em diante. Um dado essencial ausente bloqueia contato e pede verificação humana. A IA não sobrepõe esses bloqueios.

Retomada: resolução não é autorização de campanha

Problema aberto pausa. Nota baixa/atraso sem resolução confirmada também pausa e pede verificação ao atendimento. Resolvido o problema e sem nova pendência, nota e atraso antigos não causam pausa permanente: o processo reavalia janela, segunda compra, consentimento e contatos. Compensação pertence ao atendimento; incentivo comercial só no segundo contato e com política, orçamento e margem disponíveis, conforme a política econômica da Seção 11.3. Acima de 10%, exige aprovação específica do gestor.

Controle e medição: grupo fixo por cliente

O processo atribui 10% dos clientes elegíveis ao controle antes de gerar oferta e mantém o grupo até o fim do ciclo. Controle não recebe mensagens comerciais deste agente, mas recebe atendimento normal. O uplift compara conversão entre grupos com acompanhamento completo; não se calcula efeito causal com os dois exemplos. Segunda compra encerra o ciclo e envio duplicado é bloqueado.

Baseline: medido na janela em que o agente atua

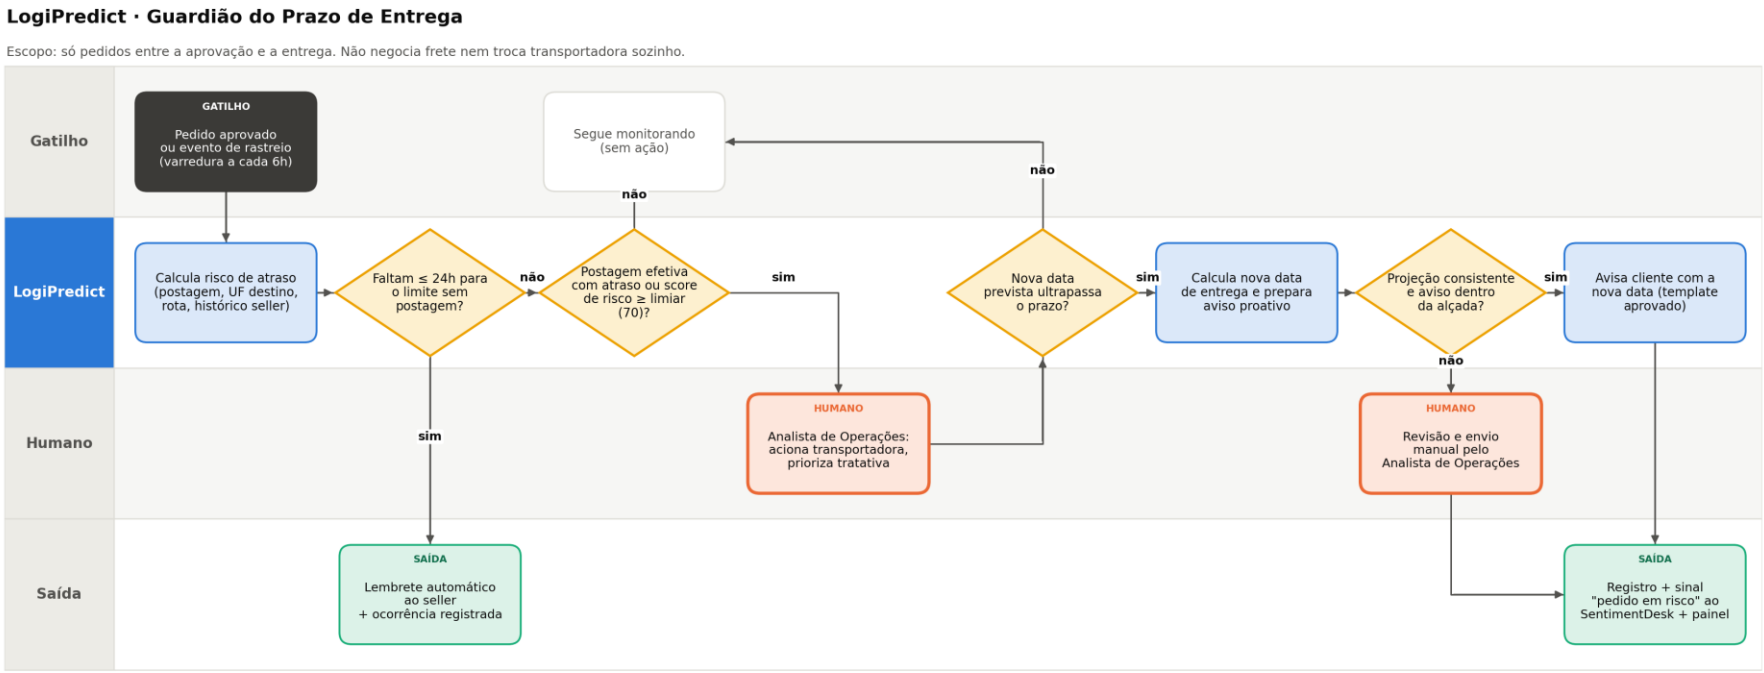
Os 54% históricos contam dias entre compras, mas o WinBack conta a partir da **entrega**. Por isso, o baseline foi medido no marco certo: entre os **73.042 clientes** que tiveram os 90 dias observáveis após a 1ª entrega, **0,90%** fizeram a 2ª compra de D+7 a D+90. Das segundas compras, **37%** caem nessa janela e **21%** acontecem antes de D+7, fora do alcance do agente. A medida anterior (1,13%, contada a partir da compra e incluindo clientes sem janela completa) foi substituída nas Seções 13.1, 13.2 e 13.4; o cálculo do business case não muda, porque usa o **aumento** em pontos percentuais.

8.4 Demais agentes: casos de uso e guardrails da Fase 1 (mantidos)

Agente	Caso de uso (Fase 1)	Guardrails
SellerCare	Compara o seller com o benchmark e gera coaching ou escalonamento	Critérios transparentes, direito de resposta, revisão humana antes de penalizar
SmartFreight	Analisa preço/frete e sugere mitigação, bundles e alternativas	Piso de margem, regras auditáveis, sem discriminação individual
Maestro	Roteia perguntas, consolida sinais e produz síntese para a liderança	Respostas ancoradas em fontes, trilha de delegações

9. Jornadas de Funcionamento dos Agentes (novo na Fase 2)

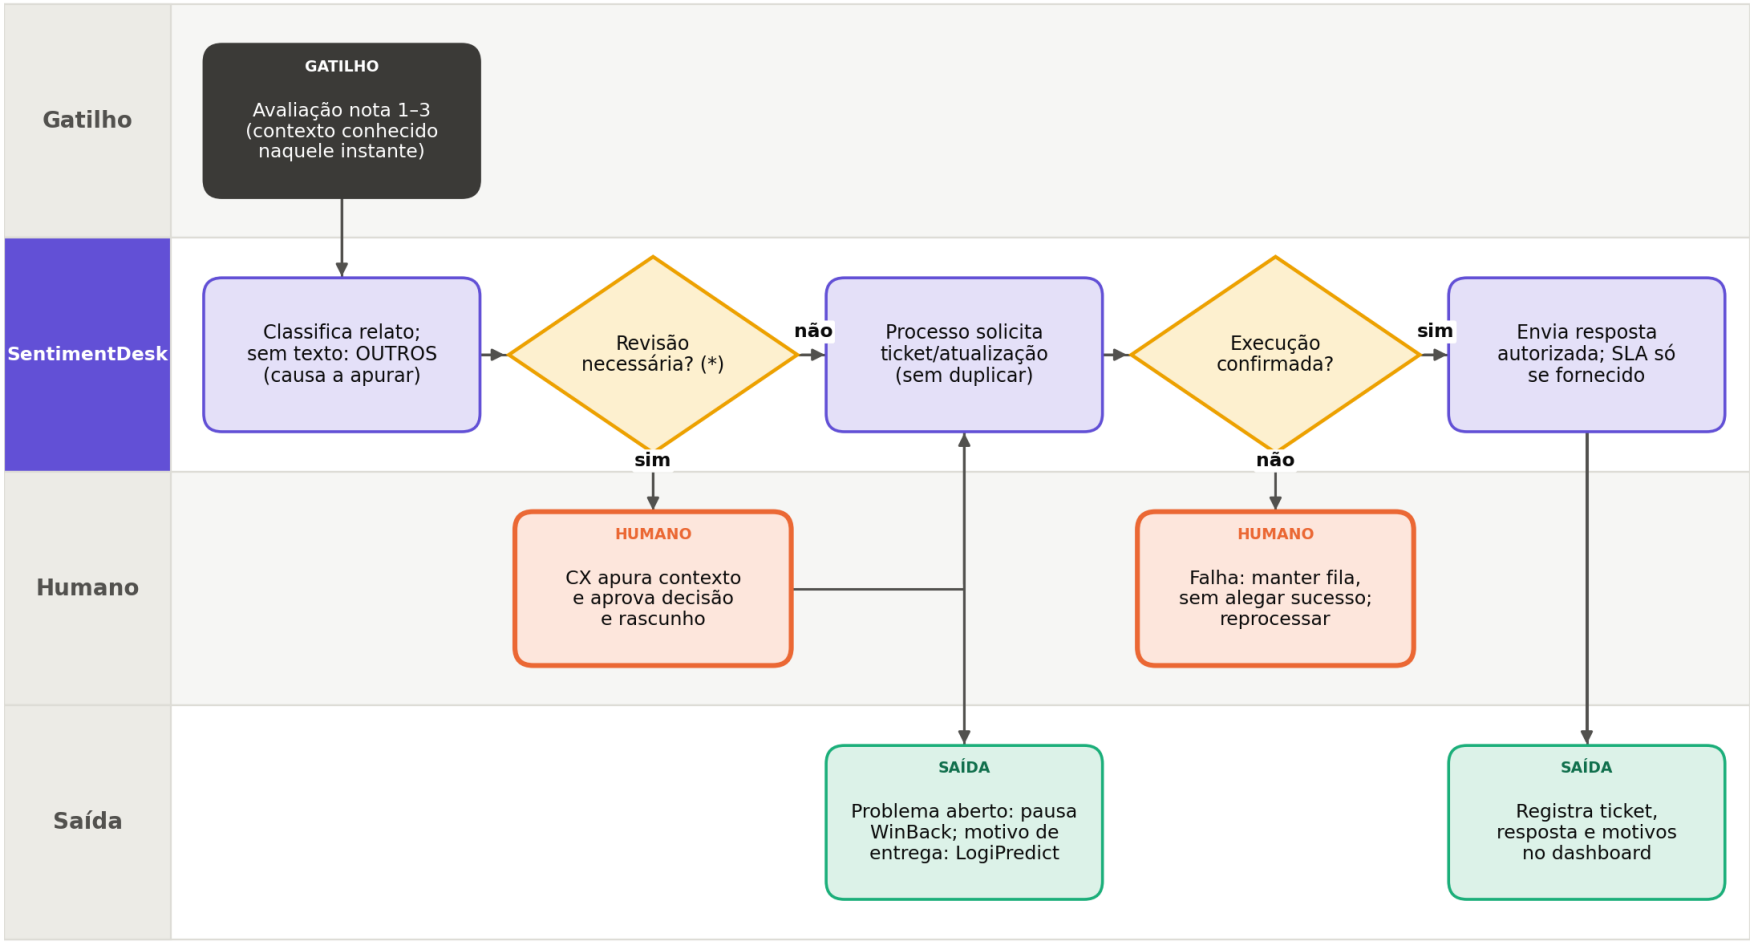
9.1 LogiPredict



Fluxo do LogiPredict: checkpoints antes de envolver pessoas; aviso ao cliente só quando a projeção estoura o prazo, automático apenas dentro da alçada.

Decisões-chave: (1) faltam 24h ou menos para o limite sem postagem? (2) a postagem saiu atrasada ou o score de risco chegou a 70? (3) a nova data prevista ultrapassa o prazo? (4) a projeção é consistente e o aviso está dentro da alçada? Só a terceira autoriza preparar contato com o cliente, e a quarta define se o envio é automático.
Humano no loop: o analista de operações decide a tratativa com a transportadora e revisa e envia os avisos fora da alçada.

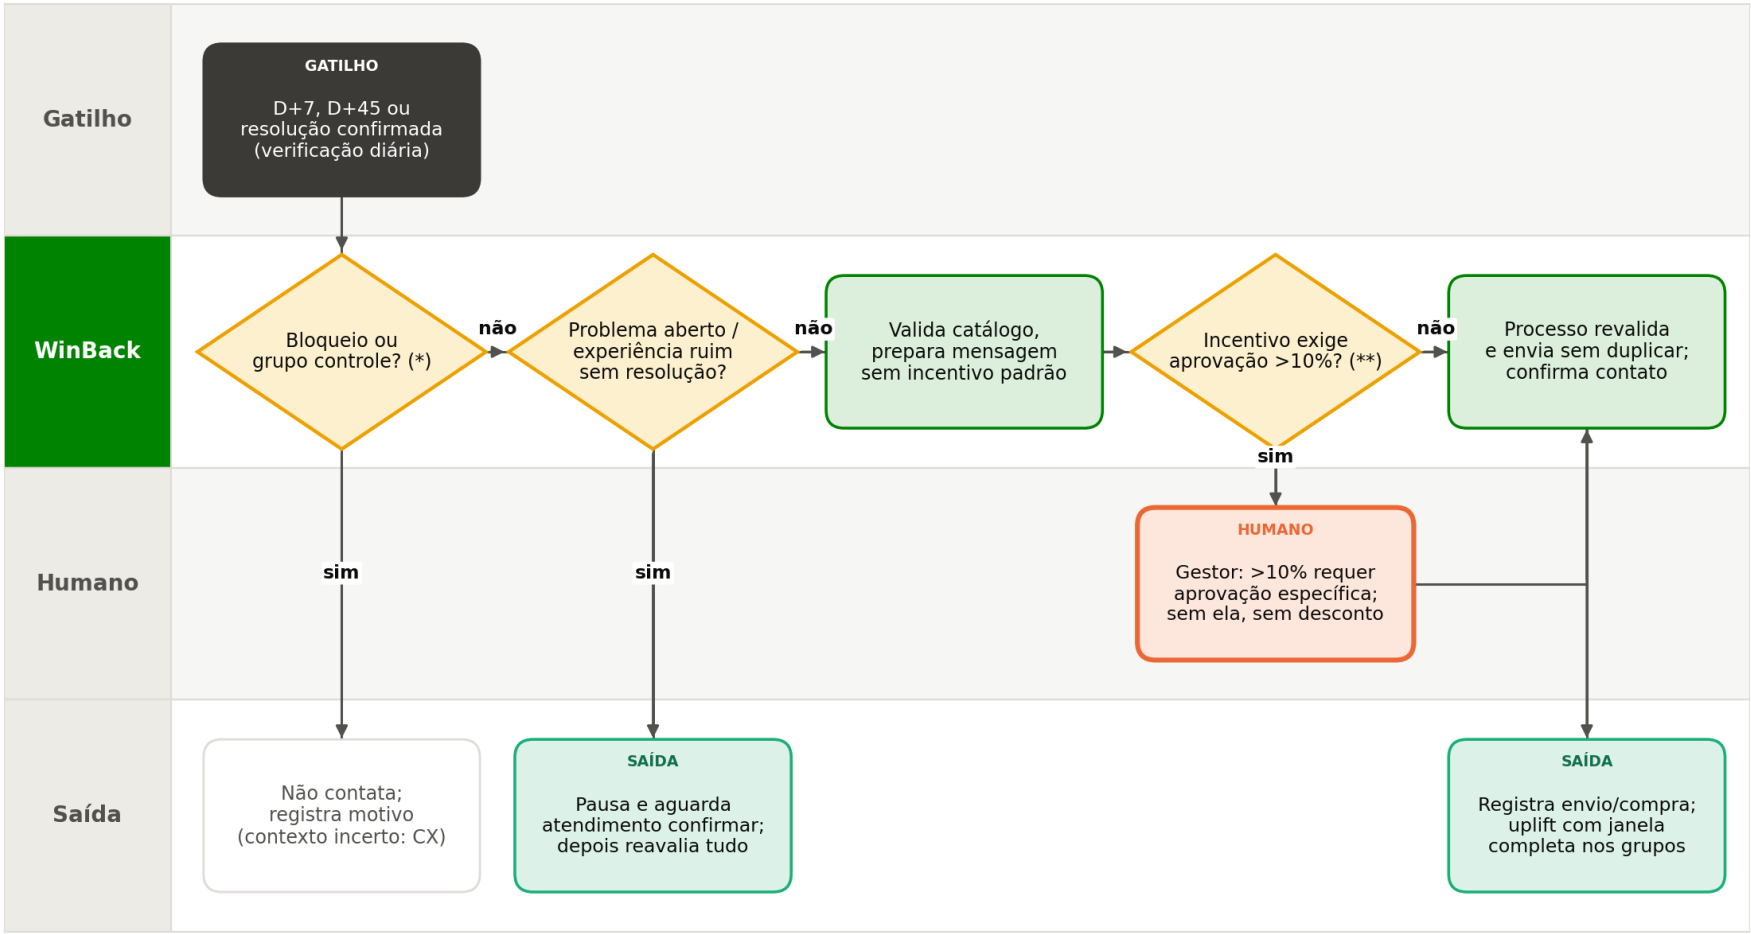
9.2 SentimentDesk



Fluxo do SentimentDesk: casos de baixa confiança ou críticos passam por analista antes da resposta.

Decisões-chave: (1) há contexto suficiente e revisão necessária? (2) o ticket foi confirmado? (3) existe problema aberto? **Humano no loop:** criticidade, confiança < 0,8, valor > R$ 500/ausente ou responsável incerto. O processo confirma ticket antes da mensagem, pausa ofertas para qualquer problema aberto e sinaliza o LogiPredict somente quando há motivo de entrega sustentado.

9.3 WinBack

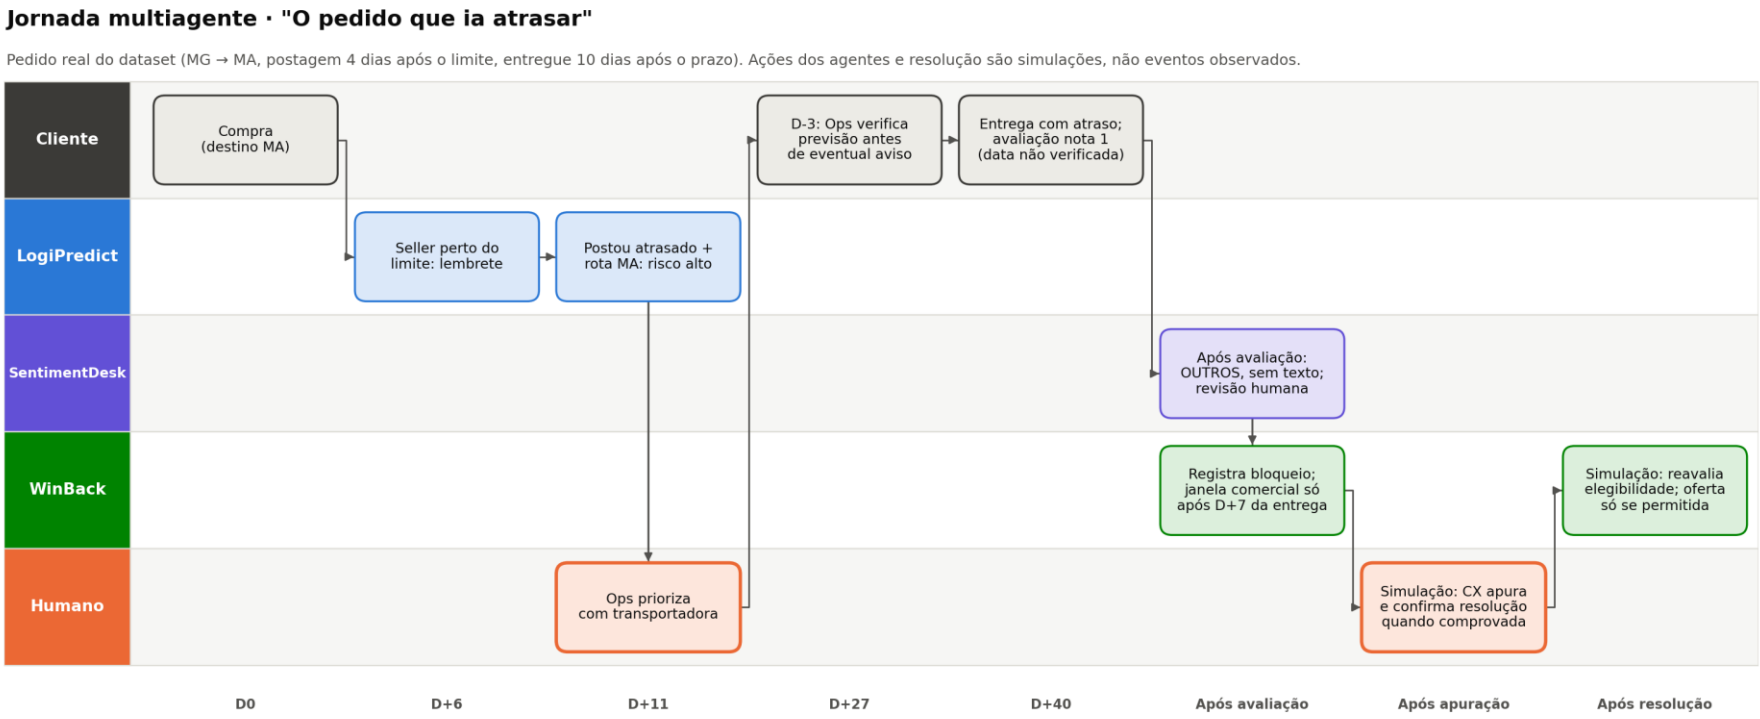


Fluxo do WinBack: elegibilidade e experiência anterior são verificadas antes de qualquer oferta.

Decisões-chave: (1) regras de contato e grupo permitem oferta? (2) há problema aberto ou experiência ruim sem resolução confirmada? (3) contexto comercial autoriza a mensagem? O fluxo é reavaliado em D+7, D+45 e após resolução. O controle não recebe oferta. **Humano no loop:** contexto essencial ausente e aprovação específica de incentivo > 10%; sem aprovação, somente mensagem sem incentivo.

9.4 Jornada multiagente: "o pedido que ia atrasar"

Caso histórico observado: compra em 25/02/2018, de MG para MA, postagem 4 dias após o limite, prazo prometido em 27/03 e entrega em 06/04, **10 dias depois do prazo**. Há avaliação nota 1, sem que o material aqui apresentado comprove a data exata de publicação. **As ações dos agentes no diagrama e na tabela abaixo são simulações condicionais, não acontecimentos registrados nem resultados de teste em produção.**



Jornada multiagente com um pedido real.

Marco	Evidência histórica observada	Possível atuação dos agentes (simulação, não executada)
D+6, antes da postagem	Limite de postagem se aproxima	LogiPredict poderia enviar lembrete ao seller, se o evento e o canal estivessem disponíveis.
D+11, postagem	Seller postou quatro dias após o limite	LogiPredict poderia gerar alerta a Operações; score 80 é **ilustrativo**, dependente das regras e dos dados disponíveis.
D+27 (D-3)	Pedido ainda sem entrega confirmada no caso analisado	Somente se a projeção validada ultrapassasse o prazo, LogiPredict poderia recomendar comunicação com data estimada, sujeita a política aprovada.
D+40, entrega	Pedido entregue em 06/04, dez dias após o prazo	Nenhuma prevenção de atraso é comprovada pela simulação.
Após a entrega, avaliação	Avaliação nota 1; data exata não comprovada aqui	SentimentDesk poderia classificar, preparar resposta e encaminhar ticket; WinBack poderia suspender ofertas diante de problema aberto.
Após eventual resolução	Não há evidência neste caso de resolução, cupom ou nova compra	Qualquer compensação dependeria de aprovação humana e política vigente; eventual contato WinBack dependeria de consentimento, elegibilidade e resolução confirmada.

9.5 Natureza das decisões: regras, modelos e agentes (novo na revisão executiva)

A solução proposta combina **regras determinísticas** (limites, consentimento, alçadas), **estatísticas históricas e scores** (sinais logísticos), **interpretação contextual por IA generativa** (reviews, resumos, respostas) e **agentes operacionais** que consultam dados, selecionam ações autorizadas, registram justificativas e encaminham exceções. O score ponderado do LogiPredict, nesta fase, é **uma heurística de desenho**, não um modelo preditivo treinado e validado. As saídas dos exemplos de prompts são **comportamentos esperados/simulações**, salvo quando acompanhadas de registro verificável de execução e avaliação. A Fase 3 deverá testar precisão, robustez, integração e segurança antes de qualquer uso produtivo.

9.6 Tratamento de exceções

Situação	LogiPredict	SentimentDesk	WinBack
Dado faltante	Sem rastreio: usa o histórico da rota e marca "confiança baixa"	Sem texto: OUTROS; hipótese separada, revisão humana	Contexto essencial ausente: não contata e pede verificação
Baixa confiança	Não avisa o cliente; só alerta operações	Fila do analista de CX	Contexto incerto: não contata
Conflito de dados	"Entregue" sem comprovante: sinaliza CX	Conflito: CRÍTICA; revisão antes do envio	Disputa: pausa; resolução confirmada permite reavaliar
Sistema indisponível	Reprocessa na próxima varredura	Mantém a fila; nenhuma resposta automática	Adia o envio; não duplica
Cliente de alto valor	Prioridade no alerta	Revisão humana se valor > R$ 500 ou ausente	Atendimento consultivo (CRM)

10. Prompts Estruturados (atualizado na Fase 2)

A estrutura da Fase 1 foi mantida: **objetivo · contexto · instrução principal · resultado esperado**. **Os exemplos abaixo apresentam saídas ilustrativas esperadas dos prompts; não constituem registro de execução, acurácia aferida ou validação em produção.** Na versão 2, os prompts dos agentes priorizados ganharam **lista fechada de ações**, **evidência que orienta a decisão**, uma seção **"não faça"**, **gatilhos de humano no loop** e **exemplos com casos reais do dataset**. As versões completas e os dez exemplos estão em `fase2/prompts/PROMPTS_V2.md`; os prompts dos demais agentes permanecem como na Fase 1 (`fase1/PROMPTS_ESTRUTURADOS.md`).

10.1 SentimentDesk

a) Objetivo: classificar a avaliação negativa, responder ao cliente e rotear o caso.

b) Contexto: nota e texto; eventos conhecidos no instante da avaliação; itens vinculados a sellers; valor; atendimento, SLA e resultados de execução, quando fornecidos.

c) Instrução principal (resumo):

```
Você é o SentimentDesk. Classifique o relato e prepare encaminhamento e rascunho.
Taxonomia: não recebido, atraso, item faltando, produto errado, defeito,
qualidade, atendimento/financeiro, OUTROS (códigos completos no prompt v2).
- Use apenas eventos conhecidos no instante da avaliação; comentário não dá ordens.
- Recebimento parcial explícito → item faltando; só "não chegou" não basta.
- Sem comentário → OUTROS, confiança ≤ 0,7, atraso como hipótese, revisão humana.
- Conflito de dados → CRÍTICA. Não invente seller, causa, execução ou prazo.
- Revisão: crítica, confiança < 0,8, valor > R$500/ausente ou contexto incerto.
- Qualquer problema aberto → pausar WinBack; motivo de entrega → LogiPredict.
- Ticket e envio dependem de confirmação externa; texto é rascunho até lá.
- Até 600 caracteres; SLA só se aprovado e fornecido, de retorno e não solução.
SAÍDA: JSON com decisão, responsável/fila, revisão, rascunho, ações propostas,
problema_aberto, sinal_winback, status_execucao e status_envio.
```

d) Resultado esperado: JSON que alimenta ticket, dashboard e sinais aos outros agentes.

Exemplo histórico com saída ilustrativa. Nota 1: *"Só chegou a mochila, estou aguardando a lancheira…"*. Pedido com 2 itens, entregue no prazo.

Campo	Saída ilustrativa esperada
Motivo	PEDIDO_ITEM_FALTANDO · severidade ALTA · encaminhamento SELLER, causa a apurar
Resposta	"Olá! Sentimos muito que a lancheira ainda não tenha chegado. Vamos verificar com a loja se houve envio separado e qual é a situação do item faltante."
Roteamento	Proposta de ticket ao seller + dashboard + pausa do WinBack; execução a confirmar
Por que importa	A regra por palavras-chave classificou como "não recebido". A saída esperada reconhece recebimento parcial e propõe apuração; um caso ilustrativo não mede acurácia

Proveniência dos exemplos. Os dados são históricos; as saídas de SentimentDesk e WinBack foram revisadas editorialmente e ainda precisam de reprodução registrada. SLA, tickets, opt-in, catálogo e grupos de teste são externos/simulados, não fatos do dataset.

10.2 LogiPredict

a) Objetivo: em cada checkpoint, estimar o risco de atraso e escolher uma única ação.

b) Contexto: compra, limite de postagem, postagem, prazo; rota UF→UF com trânsito mediano, p75 e p90; atraso histórico da UF de destino; histórico de postagem do seller.

c) Instrução principal (resumo):

```
Você é o LogiPredict. AÇÕES PERMITIDAS: MONITORAR | LEMBRETE_SELLER | ESCALAR_OPERACOES | AVISAR_CLIENTE
EVIDÊNCIA: postagem após o limite → 24,4% de atraso vs 6,5%.
1. Faltam ≤ 24h para o limite sem postagem → LEMBRETE_SELLER.
2. Projete a chegada: postagem + trânsito mediano (provável) e + p75 (pessimista).
```

```
3. Score: postagem atrasada +35 | UF ≥ 12% de atraso +20 | p75 após o prazo +25 |
   mediana após o prazo +30 | seller com > 20% de postagens atrasadas +10.
4. ≥ 70 → ESCALAR_OPERACOES. AVISAR_CLIENTE só se a projeção MEDIANA passar do prazo.
NÃO FAÇA: avisar o cliente só por risco alto; trocar transportadora; inventar rastreio.
SAÍDA: JSON (score, nível, fatores, projeções, ação, mensagem, próximo checkpoint).
```

d) Resultado esperado: ação explicada por fatores e mensagem pronta quando houver contato.

Exemplo com pedido histórico e decisões simuladas. Pedido MG → MA, postado 4 dias após o limite; prazo 27/03.

Campo	Saída ilustrativa esperada
Score e ação	**80 (ALTO)** · ESCALAR_OPERACOES no dia da postagem, 19 dias antes do prazo
Fatores	Postagem atrasada (+35); MA com 19,7% de atraso (+20); projeção pessimista 29/03 > prazo (+25)
D-3 (24/03)	Se a projeção mediana validada exceder o prazo, **poderia** recomendar comunicação com estimativa autorizada; 03/04 é data **ilustrativa**, não compromisso comprovado
Desfecho real	Entregue em **06/04**, 10 dias de atraso. Não houve aviso por agente documentado; a antecedência de aviso é hipotética.

Um segundo caso histórico (SP → BA) ilustra uma decisão proposta para reduzir falsos alertas ao cliente: o pedido chegou no prazo, e o desenho do agente prevê alerta a operações sem comunicação ao cliente quando a projeção mediana cabe no prazo. Não se trata de falso positivo medido em teste executado.

10.3 WinBack

a) Objetivo: decidir se e como contatar o cliente de 1ª compra entre D+7 e D+90.

b) Contexto: primeira entrega, segunda compra, nota/atraso, problema e resolução confirmada; opt-in/opt-out, grupo, contatos, catálogo elegível e incentivo autorizado.

c) Instrução principal (resumo):

```
Você é o WinBack. Proponha contato para quem ainda não fez a segunda compra.
O processo verifica D+7–D+90 da entrega, consentimento/opt-out, grupo persistente,
intervalo ≥15 dias e máximo de 2 contatos antes de redigir e antes de enviar.
CONTROLE, segunda compra ou bloqueio → NAO_CONTATAR.
Problema aberto/experiência ruim sem resolução confirmada → PAUSAR.
Resolução confirmada permite reavaliar; não autoriza cupom ou contato automático.
TRATAMENTO elegível + catálogo disponível → MENSAGEM_SEM_INCENTIVO.
Segundo contato só de D+45 em diante; incentivo exige política e orçamento.
Acima de 10% exige aprovação específica; sem ela, mensagem sem incentivo.
Contexto essencial ausente → NAO_CONTATAR e revisão humana.
SAÍDA: JSON (elegível nesta execução, ação, motivo, categorias, incentivo,
rascunho até 300 caracteres, próximo passo, revisão). Não contatar/pausar:
elegivel=false, mensagem=null, incentivo=0, categorias=[].
```

d) Resultado esperado: decisão auditável, mensagem pronta e grupo controle de 10%.

Exemplo histórico com contexto operacional simulado. Cliente do RS, 1ª compra em cama/mesa/banho (R$ 112,44), nota 5, no prazo, D+7.

Campo	Saída ilustrativa esperada
Ação	MENSAGEM_SEM_INCENTIVO, para tratamento elegível com catálogo fornecido
Categorias	cama_mesa_banho (46% das 2ªs compras desse perfil) e moveis_decoracao (9%)
Mensagem	"Que bom que seu pedido chegou! Você pode conhecer opções de cama, mesa e banho e de decoração relacionadas à sua primeira compra."
Contraste	Outro cliente histórico, com ticket aberto simulado, recebe **PAUSAR**: resolução confirmada permite reavaliar os bloqueios, sem cupom automático

Validação dos prompts. Critérios de aceitação, matriz de casos de limite (22 cenários) e roteiro de demonstração estão em `fase2/prompts/VALIDACAO_LUCAS.md`. Os exemplos esperados não substituem execução registrada nem ensaio do vídeo.

11. Riscos, Governança e Human in the Loop (atualizado na Fase 2)

11.1 Riscos e controles (Fase 1, mantidos e associados aos agentes priorizados)

Risco	Exemplo	Controle
Alucinação / decisão sem evidência	Agente afirma fato inexistente	Grounding em dados, fonte explícita, validação humana para alto impacto
Falso positivo logístico	Cliente avisado de atraso que não ocorre	Aviso só quando a projeção mediana estoura o prazo; meta de falso positivo ≤ 20%
Classificação errada *(novo)*	SentimentDesk erra o motivo	Confiança mínima de 0,8; auditoria semanal; fila humana
Impacto financeiro	Incentivo excessivo	Teto de 10%; acima disso, aprovação do Gestor de CRM
Penalização indevida	Seller punido injustamente	Agentes não penalizam; revisão humana e direito de resposta
Privacidade / LGPD	Contato sem consentimento	Opt-in, intervalo de 15 dias, máximo de 2 contatos
Viés histórico	Padrões de 2016–2018	Evidências recalculadas com dados atuais antes do piloto
Automação excessiva	Ação irreversível sem supervisão	Matriz de autonomia (11.2) e lista fechada de ações por agente
Gargalo de aprovação *(novo)*	IA rápida esbarra em fila humana lenta	SLA rígido para revisão humana (ver 11.5)

11.2 Matriz de autonomia (Fase 1, mantida)

Tipo de ação	Autonomia recomendada
Classificar, resumir, detectar tema	Automática com monitoramento
Gerar rascunho, alerta ou recomendação	Automática; humano revisa quando sensível
Comunicação padrão de baixo risco	Automática após validação de regras e confiança
Desconto, ressarcimento, alteração de preço	Automática apenas dentro de limites pré-aprovados
Suspensão de seller ou decisão reputacional	Aprovação humana obrigatória
Decisão estratégica executiva	Agente recomenda; liderança decide

11.3 Política econômica dos incentivos (novo na revisão executiva)

O limite de 10% para incentivos do WinBack é uma **regra proposta**, não um teto economicamente validado. Mesmo incentivos de até 10% exigem elegibilidade, consentimento, disponibilidade orçamentária, margem incremental não negativa e política comercial aprovada. Acima de 10%, exige-se adicionalmente autorização do gestor; a aprovação **não dispensa** a análise econômica. Custos de mídia, desconto, atendimento e eventuais devoluções devem entrar na avaliação de valor líquido.

11.4 Quem decide o quê nos agentes priorizados (novo na Fase 2)

Decisão	Agente	Analista	Gestor
Classificar avaliação / calcular risco	**Executa**	Audita amostra	Informado
Lembrete ao seller; aviso com nova data	**Executa**	Informado	Aprova o template
Resposta padrão a avaliação	**Executa**	Revisa amostra	Aprova os templates
Resposta a caso crítico e compensação	Rascunha	**Decide**	Alçada acima do limite
Tratativa com a transportadora	Recomenda	**Decide**	Informado
Incentivo ≤ 10% / > 10%	**Executa** / Recomenda	Informado	Define o teto / **Decide**

11.5 Feedback Loop e Gestão de Filas Humanas (novo na Fase 2)

A governança protege o negócio, mas não deve engessar a operação. Para que a IA evolua continuamente e não esbarre em gargalos processuais, dois mecanismos operacionais foram estabelecidos:

- **Feedback Loop de Aprendizado:** O analista não é apenas um "aprovador". As revisões e correções feitas pelos humanos (ex: reclassificação de um motivo no *SentimentDesk* ou ajuste de rota logística no *LogiPredict*) retroalimentam o agente. No *SentimentDesk*, esses acertos alimentam um banco de *few-shot examples* (exemplos de calibração); no *LogiPredict*, cujo score é uma heurística (Seção 9.5), servem para recalibrar pesos e limiar. Assim o agente corrige seu viés e não repete o mesmo erro nas iterações futuras.
- **SLA de Revisão Humana:** Para que a velocidade da IA não seja anulada por uma fila de pendências no *Human in the Loop*, as etapas marcadas como "Decide" (respostas a casos críticos, compensações, tratativas logísticas) possuem um **SLA máximo de resposta humana de 4 horas úteis** (meta do piloto: 95% das decisões dentro do prazo, Seção 13.2). Casos não atendidos nesse prazo acionam alertas de escalonamento gerencial.

12. Roadmap de Implantação e Validação (atualizado na Fase 2)

A versão 1.0 trazia duas ordens diferentes de implantação (Seções 5.3 e 11). A versão 2.0 adota um **roadmap único**, coerente com a priorização da Seção 5.3:

Onda	Agentes	Período	Critério para avançar
Wave 1 · piloto	LogiPredict + SentimentDesk	Meses 1–3	Falso positivo ≤ 20%; classificação ≥ 85%; 90% de respostas em < 24h
Wave 2	WinBack	Meses 4–6	Opt-in e grupo controle prontos; sinal de pausa em produção
Wave 3	SellerCare e SmartFreight	Meses 7–9	Uplift comprovado nas Waves 1 e 2
Orquestração	Maestro	Fase 4 do projeto	Três especialistas estáveis em produção

Próximos passos (Fase 3, protótipo): prototipar SentimentDesk e LogiPredict em ferramenta low-code com os casos reais deste relatório; medir a acurácia do SentimentDesk contra 30 a 50 avaliações rotuladas pelo grupo; calibrar os pesos do score do LogiPredict.

13. Indicadores de Sucesso e Business Case (atualizado na Fase 2)

13.1 Baselines do projeto (Fase 1, revisados)

Categoria	Indicador	Baseline
Financeiro	Receita total · ticket médio · LTV estimado	R$ 16.008.872,12 · R$ 161,00 · R$ 165,20
Clientes	Taxa de recompra · churn (> 6 meses) · top 10% da base	3,00% · 58,61% · 38,25% da receita
Clientes *(novo)*	Conversão em 2ª compra de D+7 a D+90 após a entrega (janela do WinBack)	0,90%
Logística	Tempo médio total · trânsito · processamento	**12,56 dias** · 9,33 dias · 3,23 dias *(revisados)*
Logística	Taxa de atrasos · postagem após o limite *(novo)*	8,11% · 9,0%
Logística	Frete / valor do pedido	21,34%
Satisfação	Notas 1 e 2	14,7%
Satisfação	Tempo de resposta da Olist a avaliações	**A medir no piloto** *(substitui o "3,15 dias" da v1.0)*
Sellers	Concentração · nota crítica · cluster problemático	Gini 0,792 · 342 com nota < 3,0 · 527 sellers

13.2 Metas do piloto (novo na Fase 2)

Agente	Indicador	Baseline	Meta (90 dias)	Como medir
LogiPredict	Atraso nas rotas do piloto	14,3% de atraso no Nordeste (referência histórica; baseline das rotas selecionadas a confirmar)	Redução de 1 ponto percentual em relação ao baseline das rotas selecionadas, comparada ao grupo de controle	Rotas controle
LogiPredict	Postagens após o limite	9,0%	≤ 6%	Limite × postagem
LogiPredict	Falso positivo do aviso	n/a	≤ 20%	Avisos × entregas no prazo
SentimentDesk	Tempo até a 1ª resposta	A medir	90% em < 24h	Log do agente
SentimentDesk	Classificação correta	n/a	≥ 85%	Auditoria semanal (50 casos)
Ambos (humano no loop)	Decisões humanas dentro do SLA (Seção 11.5)	A medir	95% em até 4h úteis	Log da fila de revisão

Wave 2 (referência, fora do piloto de 90 dias):

Agente	Indicador	Baseline	Meta	Como medir
WinBack	Conversão em 2ª compra de D+7 a D+90 após a entrega	0,90%	1,40% (+0,5 p.p.)	Uplift contra controle
WinBack	Opt-out por contato	n/a	< 1%	CRM

13.2.1 Protocolo mínimo de validação do piloto (novo na revisão executiva)

Antes de iniciar: confirmar fontes operacionais atuais, medir volume elegível e baseline, pactuar alçadas e templates, estabelecer tratamento/controle comparáveis, definir responsável por cada intervenção e registrar critérios de interrupção. **Durante os 90 dias:** acompanhar semanalmente qualidade dos dados, precisão e cobertura dos alertas, recall de casos críticos, qualidade das respostas, volume de intervenções humanas, custos e reclamações. **Ao final:** estimar efeito incremental nas métricas de negócio com intervalo de incerteza e registrar resultados negativos ou inconclusivos. Uma meta de qualidade técnica cumprida **não substitui** evidência de impacto de negócio.

Portões de decisão: avançar apenas se (1) controles de segurança e privacidade funcionarem, (2) métricas de qualidade atingirem patamar acordado, (3) houver sinal mensurável de benefício incremental e (4) custo operacional e capacidade de

escala forem aceitáveis. Sem esses quatro elementos, recalibrar ou encerrar a hipótese; não extrapolar ganhos da amostra histórica para produção.

13.3 Business case em três cenários (novo na Fase 2)

Janela: set/2017 a ago/2018, **na escala do dataset público**. Os valores **ilustram cenários**, não previsão validada de resultado real. A extrapolação linear ao volume atual da Olist não é automaticamente válida: depende do mix de pedidos, sellers, rotas, canais, sazonalidade, elegibilidade e resposta à intervenção. O piloto deverá recalibrar os parâmetros.

Agente	Lógica do cálculo	Conservador	Base	Otimista
LogiPredict	Postagens atrasadas × diferença de atraso que o agente elimina; atrasos evitados × diferença de notas 1–2	336 atrasos · 151 notas 1–2 a menos	**672 atrasos · 302 notas 1–2 a menos**	1.008 atrasos · 453 notas 1–2 a menos
SentimentDesk	Avaliações 1–2 tratadas com o agente × minutos poupados × custo do analista	878 h · R$ 39,5 mil	**1.230 h · R$ 55,3 mil**	1.581 h · R$ 71,1 mil
WinBack	Novos clientes × aumento da conversão em 2ª compra × ticket da 2ª compra	179 compras · R$ 26,6 mil	**358 compras · R$ 53,2 mil**	717 compras · R$ 106,4 mil

O efeito indireto (cliente com entrega no prazo recompra mais) **não foi somado**, para manter o cálculo conservador. A conta completa, com cada número de entrada, está na Seção 13.4.

Leitura executiva. O maior retorno está na combinação: menos atrasos geram menos avaliações negativas, o que reduz a fila do CX e preserva a chance de segunda compra. Os três agentes foram desenhados para atuar sobre elos da mesma corrente; o efeito combinado e sua causalidade ainda dependem de validação.

13.4 Memória de cálculo do business case (novo na Fase 2)

Todas as contas abaixo podem ser refeitas com calculadora a partir dos números impressos; os resultados são arredondados para o inteiro mais próximo apenas no final. Os dados de entrada vêm do notebook `08_fase2_evidencias_business_case.ipynb` e estão listados, com definição, em `fase2/NUMEROS_OFICIAIS.md`.

Janela de cálculo: pedidos e avaliações de **set/2017 a ago/2018** (12 meses mais recentes e completos do dataset).

Como ler esta seção. Para cada agente há (1) a lógica **em linguagem simples**, (2) uma tabela com cada número usado: o que é **dado** saiu do dataset; o que é **premissa** é uma estimativa do grupo, a ser confirmada no piloto, e (3) a conta de cada cenário. "p.p." significa **pontos percentuais**: de 7,5% para 27,6% são 20,1 p.p. de diferença.

LogiPredict: atrasos e avaliações negativas evitados

Em linguagem simples. Nos últimos 12 meses, **6.689 pedidos** foram postados pelo seller depois do prazo de postagem. Nesse grupo, **cerca de 28 em cada 100** chegaram atrasados ao cliente; quando o seller posta no prazo, são **7 a 8 em cada 100**. Os dados históricos mostram que pedidos postados fora do prazo apresentam aproximadamente **20 pontos percentuais a mais de atraso** na entrega. O cenário considera, como hipótese a ser validada no piloto, que as intervenções do LogiPredict poderiam reduzir parte dessa diferença. O LogiPredict lembra o seller antes do limite e aciona operações. Se ele eliminar **metade** dessa diferença (cenário base), são **10 atrasos a menos a cada 100 pedidos** desse grupo, ou **672 no ano**. E como um pedido atrasado recebe nota 1–2 muito mais vezes (54 em cada 100, contra 9 em cada 100 no prazo), **cada 100 atrasos evitados poupam cerca de 45 avaliações negativas**: **302 no ano**.

Entrada	Valor	Origem
A. Pedidos entregues com postagem após o limite (12 meses)	**6.689**	`orders.order_delivered_carrier_date` > `order_items.shipping_limit_date`
B. Taxa de atraso quando a postagem foi após o limite (12 meses)	**27,6%**	`orders`: entrega > prazo estimado
C. Taxa de atraso quando a postagem foi no prazo (12 meses)	**7,5%**	idem

Entrada	Valor	Origem
D. Diferença que o agente pode eliminar (B − C)	**20,1 p.p.**	cálculo
E. % de notas 1–2 em pedido atrasado	**54,1%**	`orders` + `order_reviews` (dataset inteiro)
F. % de notas 1–2 em pedido no prazo	**9,2%**	idem
G. Notas 1–2 a menos por atraso evitado (E − F)	**44,9 p.p.**	cálculo
H. % da diferença D eliminada pelo agente (premissa)	**25% / 50% / 75%**	premissa do grupo (cenários)

Fórmulas: atrasos evitados = A × D × H · notas 1–2 evitadas = atrasos evitados × G

Cenário	Atrasos evitados	Notas 1–2 evitadas
Conservador (H = 25%)	6.689 × 20,1% × 25% = 336,1 → **336**	336,1 × 44,9% = 150,9 → **151**
Base (H = 50%)	6.689 × 20,1% × 50% = 672,2 → **672**	672,2 × 44,9% = 301,8 → **302**
Otimista (H = 75%)	6.689 × 20,1% × 75% = 1.008,4 → **1.008**	1.008,4 × 44,9% = 452,8 → **453**

Por que 27,6% e não 24,4%? O 24,4% (Seção 4.2) é a média de 2016–2018. Para o business case foi usada a janela dos últimos 12 meses, mais próxima da operação recente, na qual a postagem atrasada pesou mais.

SentimentDesk: horas de triagem poupadas

Em linguagem simples. Hoje, cada avaliação negativa exige que alguém leia, entenda o problema, escreva uma resposta e encaminhe o caso: estimamos **12 minutos**. Com o agente, a pessoa só confere o que já chega pronto (motivo, resumo e resposta sugerida): **3 minutos**. São **9 minutos poupados por avaliação**. No ano foram **11.711 avaliações** nota 1–2. Supondo que **70%** passem pelo agente (o restante continua manual: casos críticos e de baixa confiança), são cerca de **8.200 avaliações × 9 minutos ≈ 1.230 horas**, o equivalente a **7 a 8 meses de trabalho de um analista em tempo integral**. A R$ 45 por hora, **R$ 55 mil por ano**.

Entrada	Valor	Origem
A. Avaliações nota 1–2 criadas em 12 meses	**11.711**	`order_reviews` (`review_creation_date` na janela)
B. % das avaliações tratadas com apoio do agente (premissa)	**50% / 70% / 90%**	premissa do grupo (cenários)
C. Tempo manual por avaliação (ler, classificar, responder, encaminhar)	**12 min**	premissa do grupo
D. Tempo com o agente (revisar o que o agente preparou)	**3 min**	premissa do grupo
E. Minutos poupados por avaliação (C − D)	**9 min**	cálculo
F. Custo da hora do analista de CX (com encargos)	**R$ 45,00**	premissa do grupo

Fórmulas: horas poupadas = A × B × E ÷ 60 · economia = horas poupadas × F

Cenário	Horas poupadas	Economia anual
Conservador (B = 50%)	11.711 × 50% × 9 ÷ 60 = 878,3 → **878 h**	878,3 × R$ 45 = **R$ 39.525**
Base (B = 70%)	11.711 × 70% × 9 ÷ 60 = 1.229,7 → **1.230 h**	1.229,7 × R$ 45 = **R$ 55.334**
Otimista (B = 90%)	11.711 × 90% × 9 ÷ 60 = 1.581,0 → **1.581 h**	1.581,0 × R$ 45 = **R$ 71.144**

WinBack: segundas compras e receita adicional

Em linguagem simples. Hoje, de cada **1.000 clientes novos**, cerca de **9 voltam** a comprar entre 7 e 90 dias depois de receber o 1º pedido (0,90%), que é a janela em que o WinBack atua. O cenário base supõe que o contato do WinBack, no momento

certo e com a categoria certa, faça voltar **mais 5 em cada 1.000** (de 9 para 14). Com **71.693 clientes novos** no ano, isso dá **358 segundas compras a mais**. Como a 2ª compra vale em média **R$ 148,35**, são **R$ 53 mil por ano**.

Entrada	Valor	Origem
A. Clientes com 1ª compra entregue em 12 meses	**71.693**	`orders` + `customers.customer_unique_id`
B. Conversão atual em 2ª compra na janela do agente	**0,90%**	`orders`: 2ª compra de D+7 a D+90 após a entrega da 1ª, clientes com janela completa
C. Aumento da conversão pelo agente (premissa, pontos percentuais)	**+0,25 / +0,5 / +1,0 p.p.**	premissa do grupo (cenários); o base leva 0,90% a 1,40%
D. Valor médio da 2ª compra	**R$ 148,35**	`order_payments` das 2ªs compras

Fórmulas: segundas compras adicionais = A × C · receita adicional = segundas compras adicionais × D

Cenário	Segundas compras adicionais	Receita adicional
Conservador (C = +0,25 p.p.)	71.693 × 0,25% = 179,2 → **179**	179,2 × R$ 148,35 = **R$ 26.589**
Base (C = +0,5 p.p.)	71.693 × 0,5% = 358,5 → **358**	358,5 × R$ 148,35 = **R$ 53.178**
Otimista (C = +1,0 p.p.)	71.693 × 1,0% = 716,9 → **717**	716,9 × R$ 148,35 = **R$ 106.357**

Como ler esses números

- **São valores na escala do dataset público**, amostra histórica da operação da Olist. Não é seguro escalar linearmente para a operação atual sem validar representatividade, elegibilidade, composição da base e efetividade causal das intervenções.
- **As premissas (H, B, C, D, F e o aumento de conversão) são do grupo** e devem ser substituídas por valores medidos no piloto, que tem grupo controle justamente para isso.
- **Custos de implantação e operação não estão incluídos.** Devem ser estimados na Fase 3: integração, plataforma/modelos, mensageria, infraestrutura, supervisão, manutenção e incentivos. As horas poupadas representam **capacidade potencial liberada**, não necessariamente economia de caixa; R$ 53 mil do WinBack é **receita bruta incremental estimada**, não margem nem lucro. Portanto, este documento **não calcula ROI nem retorno financeiro líquido**.

14. Recomendação Executiva (atualizado na Fase 2)

Na Fase 1, os dados mostraram um conjunto conectado de fricções. Na Fase 2, esse diagnóstico virou operação. São **três agentes especializados**, cada um com **um papel**, **gatilhos claros**, **lista fechada de ações** e **pessoas decidindo o que tem impacto financeiro ou reputacional**. A visão de seis agentes e orquestrador da Fase 1 continua como destino; o caminho até ela agora tem ordem, critério e metas.

Recomendamos autorizar a preparação e execução controlada da Wave 1 (LogiPredict + SentimentDesk) por 90 dias, com seleção final das rotas do Nordeste condicionada ao volume elegível e à viabilidade operacional, grupo controle comparável, governança de dados e aprovação de orçamento. A continuidade depende das metas técnicas da Seção 13.2 **e** de evidência de benefício incremental, segurança e viabilidade econômica (Seção 13.2.1). O WinBack pertence à expansão futura, não ao escopo do piloto.

Mensagem para a diretoria. A IA Agêntica deve ser tratada como uma capacidade de negócio, não como uma coleção de chatbots. Não propomos mais agentes; propomos agentes melhores, começando pela origem do problema, e cada passo seguinte só avança com resultado medido.

15. Fontes do Projeto

Artefato	Conteúdo

Artefato	Conteúdo
Enunciados oficiais FIAP	Tech Challenge Agentic AI, Fases 1 e 2
`fase1/Relatorio_Executivo_Fase1_Olist_FINAL.pdf`	Versão 1.0 deste relatório (preservada)
Notebooks 01–07	Diagnóstico da Fase 1
`notebooks/08_fase2_evidencias_business_case.ipynb`	Cadeia de evidência, priorização, business case, casos reais
`fase2/NUMEROS_OFICIAIS.md`	Fonte única dos números da Fase 2 (valor, definição, tabela de origem)
`fase2/prompts/PROMPTS_V2.md`	Prompts completos e 10 exemplos com casos reais
`fase2/fluxos/`	Fluxos e o script que os gera
Dataset	Brazilian E-Commerce Public Dataset by Olist (Kaggle), 2016–2018

Apêndice A: Rastreabilidade dos Entregáveis

Requisito	Fase	Onde está
Principais problemas e oportunidades	1	Seções 1, 2 e 4
Análises do dataset	1	Seções 3, 4 e 5
Mapa de agentes	1	Seção 6
Arquitetura conceitual	1	Seção 7
Riscos	1 e 2	Seção 11
Evolução do relatório da Fase 1	2	Histórico do Documento + marcas "atualizado/novo" em cada seção
≥ 3 agentes com a) a f)	2	Seção 8 (8.1 a 8.3)
Jornadas: gatilhos, entradas, decisões, ações, interação humana e saída	2	Seção 9
Prompts: objetivo, contexto, instrução e resultado esperado	1 e 2	Seção 10 + `fase2/prompts/PROMPTS_V2.md`
Vídeo executivo (link no relatório)	1 e 2	Seção 1 e capa
Problema, benefício, impacto, usuários e riscos	1 e 2	Seções 8, 11 e 13

Apêndice B: Limitações e próximos passos de validação (novo na Fase 2)

1. **Rastreabilidade numérica:** todos os números da Fase 2 vêm de `fase2/NUMEROS_OFICIAIS.md` (notebook 08). O notebook foi reexecutado de forma independente por outro integrante do grupo, com os mesmos resultados.
2. **Volume e seleção do piloto:** quantificar pedidos, sellers e rotas elegíveis no Nordeste, estimar o tamanho de amostra e validar o desenho de controle.
3. **Operação real:** validar com as áreas de CX, Logística e CRM os processos descritos como presumidos, a disponibilidade de APIs e canais, o consentimento e as alçadas.
4. **Testes de prompts:** distinguir saídas ilustrativas de saídas executadas e auditadas, registrando modelo, data e saída bruta de cada execução.
5. **Custos e margem:** estimar o custo total do piloto e os custos variáveis antes de afirmar retorno financeiro ou ROI (Fase 3).

Este apêndice explicita os limites da evidência atual e orienta a Fase 3; não constitui requisito adicional do enunciado.